

Spark setup

Opsætning af Spark til brug i BagData 2, under wsl

Søren Magnusson
programmeringsspecialet, datateknikker

2026-09-01

Indholdsfortegnelse

1	Playbook	1
1.1	Start med at skifte til ~	1
1.2	Spark download	1
1.3	Udpak	2
1.4	Rediger .bashrc	2
1.5	Kopier spark-env.sh	2
1.6	Rediger spark-env.sh	2
1.7	Start Spark	3
2	Start og stop all	3

1 Playbook

1.1 Start med at skifte til ~

```
cd ~
```

check

```
***:~$ cd ~
***:~$ pwd
/home/[user]
```

1.2 Spark download

- Åben en browser og søg på “spark download”.
- vælg den nyeste udgave af spark
- vælg “Prebuilt with user-provided Apache Hadoop”
- klikk på linket “xxx.tgz”, neden for
- på linket “xxx.tgz” filen, højre klik og “kopier link adresse”

I konsollen, brug wget:

```
wget https://dlcdn.apache.org/spark/spark-z.z.z/spark-z.z.z-bin-without-hadoop.tgz
```

Check sparkfilens størrelse og dato

```
$ ls -l
total 1027928
drwxr-xr-x 4 smag smag      4096 Aug 31 17:25 BigData
-rw-r--r-- 1 smag smag 581280703 Apr  1 22:43 hadoop-3.5.0.tar.gz
-rw-r--r-- 1 smag smag 471301088 Jul 11 18:36 spark-4.2.0-bin-without-hadoop.tgz
```

1.3 Udpak

```
tar xvzf spark-z.z.z-bin-without-hadoop.tgz -C BigData/
```

check

```
$ ls -l BigData/
total 8
drwxr-xr-x 13 smag smag 4096 Aug 31 16:39 hadoop-3.5.0
drwxr-xr-x 13 smag smag 4096 Jul 11 18:25 spark-4.2.0-bin-without-hadoop
```

1.4 Rediger .bashrc

Tilføj nederst:

```
# Spark
export SPARK_DIST_CLASSPATH=$(hadoop classpath)
export SPARK_HOME=/home/[user]/BigData/spark-z.z.z-bin-without-hadoop
export PATH=$SPARK_HOME/bin:$PATH
export PATH=$SPARK_HOME/sbin:$PATH
```

Husk at opdatere environment ved at køre source ~/.bashrc!

1.5 Kopier spark-env.sh

I ~/BigData/spark-z.z.z-bin-without-hadoop/conf skal spark-env.sh.template kopieres til spark-env.sh:

```
cp BigData/spark-z.z.z-bin-without-hadoop/conf/spark-env.sh.template BigData/spark-z.z.z-bin-without-hadoop/conf/spark-env.sh
```

1.6 Rediger spark-env.sh

Åben filen ~/BigData/spark-z.z.z-bin-without-hadoop/conf/spark-env.sh Tilføj nederst:

```
SPARK_MASTER_HOST=0.0.0.0
```

1.7 Start Spark

```
start-master.sh  
start-worker.sh spark://localhost:7077
```

Check ved at køre et job:

```
spark-submit --master spark://localhost:7077 BigData/spark-z.z.z-bin-without-  
hadoop/examples/src/main/python/wordcount.py /user/smag/README.txt
```

💡 Hvis *wordcount* kører og viser en liste, så er du færdig!

Med mindre du vil lidt mere...

Wordcount regnes for at være “hello world” i Big Data. Det tæller hyppigheden af de ord der i en tekstfil.

I mappen `spark-z.z.z-bin-without-hadoop/examples/src/main/python` kan man finde nogle eksempler.

2 Start og stop all

Spark har to medfølgende scripts, der starter og stopper spark master og worker mv; , `start-all.sh` og `stop-all.sh`. De kører udenfor brugerens miljø, som vi har opsat i `.bashrc`.

Derfor skal man duplikere de relevante linjer fra `.bashrc` over i bunden af `~/BigData/spark-z.z.z-bin-without-hadoop/conf/spark-env.sh`:

```
HADOOP_HOME=/home/[user]/BigData/hadoop-x.x.x  
HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native  
PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/bin  
HADOOP_OPTS="-Djava.library.path=$HADOOP_COMMON_LIB_NATIVE_DIR"  
  
SPARK_DIST_CLASSPATH=$(hadoop classpath)  
SPARK_HOME=/home/smag/BigData/spark-z.z.z-bin-without-hadoop
```

Bemærk: `[user]` og `x.x.x` skal erstattes med din bruger og hadoop-versionen, du har downloadet.

Desuden behøver der ikke stå `export` foran variablerne, da de *kun* skal bruges i det script, der starter og stopper spark.

Desværre er der navnesammenfald mellem *hadoops* og *spark's* udgaver af `start-all.sh` og `stop-all.sh`. Så de skal kaldes med fuld sti, hvis man vil være sikker.

Man sikkert lave et nyt script der starter og stopper både hadoop og spark...

Start og stop hadoop

```
BigData/hadoop-x.x.x/sbin/start-all.sh  
BigData/hadoop-x.x.x/sbin/stop-all.sh
```

Start og stop spark

```
BigData/spark-z.z.z-bin-without-hadoop/sbin/start-all.sh  
BigData/spark-z.z.z-bin-without-hadoop/sbin/stop-all.sh
```